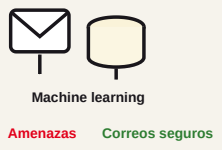
INTEGRANTES:
Sergio Galvis, Sergio Cuesta, Gloria Mozquera y Johan Ramírez
ASIGNATURA:
Metodología de la Investigación (Machine Learning)
PROGRAMA:
Ingeniería de Sistemas

CLASIFICADOR DE CORREOS DE PHISHING Y ESTAFAS

Una aproximación con regresión logística y características de texto

INTRODUCCIÓN

El phishing y las estafas por correo buscan robar información o dinero. Este proyecto entrena un clasificador de texto que estima la probabilidad de que un correo sea una estafa y mide qué tan bien generaliza ante mensajes que nunca vio.



PREGUNTA, HIPÓTESIS Y OBJETIVOS

Pregunta: ¿Cómo diseñar un modelo de clasificación de texto que identifique phishing, y qué tan bien generaliza frente a ejemplos no vistos?

Hipótesis (H_1): un clasificador entrenado identifica estafas en mensajes no vistos mejor que un clasificador de reglas fijas. **H_o:** ambos aciertan igual.

OBJETIVO GENERAL

Determinar el desempeño y la capacidad de generalización de un clasificador de texto (regresión logística) para identificar correos de phishing y estafas.

OBJETIVOS ESPECÍFICOS

1. Estimar el desempeño del modelo en correos no vistos de un corpus público, con intervalos de confianza del 95 %.
2. Comparar el modelo con un clasificador de reglas fijas y contrastar si la diferencia es estadísticamente significativa.
3. Determinar su capacidad de generalización ante mensajes nuevos en español e inglés, con redacción distinta a la del entrenamiento.
4. Identificar las limitaciones del modelo y sus causas.

METODOLOGÍA Y DISEÑO ESTADÍSTICO

Enfoque: cuantitativo, aplicado y comparativo. Diseño de evaluación de modelos con muestras retenidas (hold-out), sin intervención sobre personas.

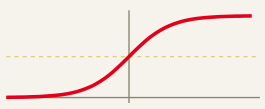
- **Muestra:** 35.612 correos únicos (Enron + SMS) y 7.000 ejemplos sintéticos en español e inglés.
- **División:** estratificada 80/10/10 con semilla fija: entrenamiento · validación (elige el modelo) · prueba (no interviene en esa elección).
- **Variables:** respuesta = estafa / legítimo; predictor = texto; factor comparado = modelo (entrenado vs. reglas fijas).
- **Métricas:** precisión, recall, F1 y tasa de falsos positivos.
- **Inferencia:** IC 95 % (bootstrap con 2.000 remuestreos; Wilson para proporciones) y prueba de McNemar exacta, α = 0,05, para muestras pareadas.
- **Validez:** mensajes de generalización escritos tras congelar el entrenamiento y prueba automática contra fuga de datos.

TAREAS

1. Recopilar y depurar los datos
2. Extraer características: palabras y letras (hashing)
3. Entrenar y comparar 7 modelos
4. Evaluar en datos retenidos
5. Probar con mensajes nuevos
6. Analizar errores y límites

Modelo: regresión logística

$$z = \beta_0 + \Sigma(\beta_i \cdot x_i) \cdot P(y=1|x) = 1 / (1 + e^{-z})$$



HALLAZGOS Y LIMITACIONES

- **Una fuga de datos, detectada y corregida.** Un primer conjunto de prueba tenía frases copiadas en el entrenamiento (F1 ≈ 1,0); al quitarlas bajó. Hoy una prueba automática lo impide.
- **La definición importó.** Estafa = intento de robar información o dinero; la publicidad legítima no cuenta. Con correo real fue peor: de 35 promociones de una bandeja personal, 19 se marcaron como sospechosas.

RESULTADOS · PROTOTIPO

Evaluación en vivo con el modelo entrenado

CORREO ANALIZADO

Estimado cliente, su cuenta bancaria ha sido bloqueada temporalmente... haga clic aquí e ingrese su contraseña actual.

PANEL DE RESULTADOS

🚨 **ESTAFA PROBABLE**

88,1 %

ANÁLISIS DE PALABRAS

bancaria	+0,57
sido	+0,20
haga	+0,20
clic	+0,19

```
z = log-odds · P(y=1|x) = sigmoide(z) · estafa ≥ 80 % · revisar 50–80 % · ok < 50 %
```

PRUEBA DE GENERALIZACIÓN

Mensajes nuevos que el modelo nunca vio:

"Tu paquete está retenido en aduana, paga la tarifa..." → **71,3 % (REVISAR)** · prototipo inicial: 2,4 %

"Your PayPal account is suspended..." → **60,9 % (REVISAR)** · prototipo inicial: 2,4 %

Contraste de H_o (McNemar exacto, 50 mensajes escritos a mano): el modelo acierta 43/50 (86 %) y el prototipo de 15 palabras fijas 32/50 (64 %); p = 0,007. Se rechaza H_o con α = 0,05.

RESULTADOS Y CONCLUSIONES

Prueba con 3.562 correos no vistos (Enron + SMS)

Precisión	Recall	F1-Score	Falsos positivos
98,87 %	**97,63 %**	**98,25 %**	**0,83 %**
IC 95 %: [98,33; 99,35]	IC 95 %: [96,82; 98,33]	IC 95 %: [97,78; 98,69]	IC 95 %: [0,48; 1,24]

17 de 2.042 correos legítimos marcados como estafa

25 + 25 mensajes escritos a mano, posteriores al entrenamiento (IC 95 % Wilson)

	Estafa	Revisar	Se escapan / correctos
25 estafas	6	16	3 se escapan (12 %; IC 4–30 %)
25 legítimos	0	4	21 correctos

El modelo generaliza muy bien en correos de Enron, pero con mensajes escritos a mano en español aproximadamente 1 de cada 8 estafas se escapa y 1 de cada 6 correos legítimos cae en "revisar". Las muestras son pequeñas y los datos en español son sintéticos. Siguiente paso: estafas reales etiquetadas.

REFERENCIAS

1. Jurafsky, D. y Martin, J. H. *Speech and Language Processing.*
2. Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR* 12.
3. Metsis, Androutsopoulos y Paliouras (2006). Spam filtering with naive Bayes – which naive Bayes? (corpus Enron-Spam).