INTEGRANTES:
[Nombres del grupo]
ASIGNATURA:
Metodología de la Investigación (Machine Learning)
PROGRAMA:
Ingeniería de Sistemas

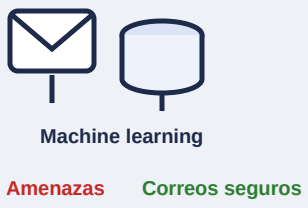
CLASIFICADOR DE CORREOS DE PHISHING Y ESTAFAS

Una aproximación con regresión logística y características de texto

Pegar logo aquí

INTRODUCCIÓN

El phishing y las estafas por correo buscan robar información o dinero. Este proyecto entrena un modelo de clasificación de texto que estima la probabilidad de que un correo sea una estafa, y mide qué tan bien generaliza ante mensajes que nunca vio.



PREGUNTA DE INVESTIGACIÓN Y OBJETIVOS

Pregunta: ¿Cómo diseñar un modelo de clasificación de texto que identifique phishing, y qué tan bien generaliza frente a ejemplos no vistos?

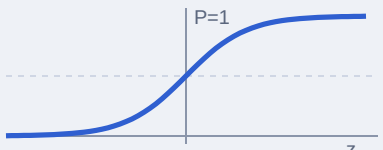
Objetivos

- Diseñar un clasificador de estafas con código accesible.
- Entrenarlo con correos públicos y ejemplos propios en español e inglés.
- Medir la generalización con mensajes nuevos y evitar el sobreajuste.

METODOLOGÍA

1. **Datos**
   35.612 correos únicos de Enron y SMS (inglés) más 7.000 ejemplos sintéticos escritos por el equipo en español e inglés.
2. **Limpieza**
   Enlaces y números se reemplazan por marcas; se quitan tildes.
3. **Características**
   Palabras, pares de palabras y fragmentos de 2 a 4 letras, con hashing.
4. **División**
   80 % entrenamiento · 10 % validación · 10 % prueba (usada una sola vez).
5. **Regresión logística**
   Convierte la evidencia del texto en una probabilidad entre 0 y 1.

$$z = \beta_0 + \Sigma(\beta_i \cdot x_i)$$
$$P(y=1|x) = 1 / (1 + e^{-z})$$



HALLAZGOS Y LIMITACIONES

- **Una fuga de datos, detectada y corregida.** Un primer conjunto de prueba tenía frases copiadas en el entrenamiento y daba F1 ≈ 1,0. Al quitarlas el resultado bajó; hoy una prueba automática impide ese cruce.
- **La definición importó.** Estafa = intento de robar información o dinero. La publicidad legítima, los códigos de verificación y los avisos del banco no cuentan. Con datos de Enron, el modelo trataba la publicidad como spam.
- **Con correo real fue peor.** De 35 promociones reales de una bandeja personal, 19 se marcaron como sospechosas.
- **Enseñar solo "no es estafa" es peligroso.** Hacía perder la detección de estafas en español; por eso cada corrección se mezcla con ejemplos antiguos.

RESULTADOS · PROTOTIPO

Evaluación en vivo con el modelo entrenado

CORREO ANALIZADO

Estimado cliente, su cuenta bancaria ha sido bloqueada temporalmente... haga clic aquí e ingrese su contraseña actual.

PANEL DE RESULTADOS

🚨 **ESTAFA PROBABLE**

88,1 %

PALABRAS QUE MÁS PESARON

bancaria	+0,57
sido	+0,20
haga	+0,20
clic	+0,19

```
z = log-odds · P(y=1|x) = sigmoide(z) · estafa ≥ 80 % · revisar 50–80 % · ok < 50 %
```

PRUEBA DE GENERALIZACIÓN

Mensajes nuevos que el modelo nunca vio:

"Tu paquete está retenido en aduana, paga la tarifa..." → **71,3 % (REVISAR)** · prototipo inicial: 2,4 %

"Your PayPal account is suspended..." → **60,9 % (REVISAR)** · prototipo inicial: 2,4 %

El prototipo inicial usaba 15 palabras fijas y dejaba pasar ambos mensajes.

RESULTADOS Y CONCLUSIONES

Prueba con 3.562 correos no vistos (Enron + SMS)

Precisión	Recall	F1	Falsos positivos
98,87 %	97,63 %	98,25 %	0,83 %

17 de 2.042 correos legítimos marcados como estafa

25 + 25 mensajes escritos a mano, posteriores al entrenamiento

	Estafa	Revisar	Se escapan / correctos
25 estafas	6	16	3 se escapan
25 legítimos	0	4	21 correctos

El modelo generaliza muy bien en correos de Enron, pero con mensajes escritos a mano en español aproximadamente 1 de cada 8 estafas se escapa y 1 de cada 6 correos legítimos cae en "revisar". Las muestras son pequeñas y los datos en español son sintéticos. Siguiente paso: estafas reales etiquetadas.

REFERENCIAS

- Jurafsky, D. y Martin, J. H. *Speech and Language Processing*.
- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR* 12.
- Metsis, Androutsopoulos y Paliouras (2006). Spam filtering with naive Bayes – which naive Bayes? (corpus Enron-Spam).